

Tema 2

Gráficos estadísticos avanzados

Carlos Castilla Ruiz

c.castilla@upm.es

Índice

1. Estructura de gráficos avanzados para distribuciones
2. Histogramas y estimación de densidad KDE
3. Gráficos de caja y violín agrupados
4. Mapas de calor de correlación

Índice

1. Estructura de gráficos avanzados para distribuciones
2. Histogramas y estimación de densidad KDE
3. Gráficos de caja y violín agrupados
4. Mapas de calor de correlación

1. Estructura de gráficos avanzados para distribuciones

Histogramas y densidad KDE (Kernel Density Estimation)

Mapeos de **distribuciones de frecuencia continuas** y estimaciones de suavizado matemático de densidad.

Construcción de **bins óptimos**.

Estimación continua kernel KDE.

Configuración con **sns.histplot()**.

Superposición semántica de grupos.

Cajas y violines de distribución

Resúmenes estadísticos bivariados y unificación de diagramas estadísticos para **comparaciones de múltiples grupos**.

Anatomía del boxplot (cuartiles).

Diagramas de violín.

Comparativa lado a lado (subplots).

Resaltado y contraste preatencional.

Mapas de calor y correlación

Matrices bidimensionales para analizar **correlaciones lineales y asimetrías** de manera compacta y ágil.

Coeficiente de correlación de Pearson.

Estilo de heatmaps con **sns.heatmap()**.

Paletas divergentes e inclusivas.

Visualización de **anotaciones directas**.

Índice

1. Estructura de gráficos avanzados para distribuciones
2. Histogramas y estimación de densidad KDE
3. Gráficos de caja y violín agrupados
4. Mapas de calor de correlación

2. Histogramas y estimación de densidad KDE

Visualización de variables cuantitativas continuas

Histograma: Divide el rango de la variable en intervalos o 'bins' y contabiliza de forma proporcional el volumen de **observaciones** en el área.

Estimación Kernel de Densidad (KDE): Curva matemática **suavizada de probabilidad continua**. Muy **sensible** a la elección del **parámetro de ancho de banda**.

Seaborn: La función '**sns.histplot(kde=True)**' unifica ambos métodos en un solo paso, permitiendo el **control del estilo y de los bins**.

Superposiciones semánticas: Utilizar el parámetro '**hue**' para **contrastar distribuciones entre categorías**, aplicando '**element='step'**' para evitar solapamientos masivos opacos.

Ejemplo: Histograma y estimación KDE con Seaborn

```
import matplotlib.pyplot as plt
import seaborn as sns
import pandas as pd
```

```
df = pd.read_csv('heart.csv')
fig, ax = plt.subplots(figsize=(8,5, 5))
```


```
# Histograma con KDE superpuesto y color de acento
sns.histplot(data=df, x='chol', kde=True, bins=30, #
'auto' color='#00629B', alpha=0.45, ax=ax)
```

```
# Limpieza de lienzo y spines
sns.despine(ax=ax, top=True, right=True)
```

```
ax.set_title('Distribución de niveles de colesterol en suero',
loc='left', pad=15)
ax.set_xlabel('Colesterol (mg/dl)')
ax.set_ylabel('Frecuencia')
```

```
# Insight: Permite evaluar asimetrías y sesgos clínicos.
```

Distribución de Colesterol Sérico: Sesgo hacia niveles de riesgo (>200 mg/dl)



Índice

1. Estructura de gráficos avanzados para distribuciones
2. Histogramas y estimación de densidad KDE
3. Gráficos de caja y violín agrupados
4. Mapas de calor de correlación

3. Gráficos de caja y violín agrupados

Comparación de estadísticas descriptivas de grupo

Diagrama de caja (Boxplot): Representa la mediana (Q2, $\leq 50\%$), los cuartiles Q1 ($\leq 25\%$) y Q3 ($\leq 75\%$) que definen la **caja central**, los **bigotes** que se extienden hasta 1.5 veces el **rango intercuartílico (Q3-Q1)**, y los **outliers** individuales.

Diagrama de violín (Violinplot): Unifica el boxplot con una **estimación de densidad KDE** rotada **simétricamente a los lados del eje central**.

Revelación de bimodalidades: A diferencia del boxplot estándar, el **gráfico de violín revela si una distribución es bimodal, trimodal, etc.** de manera directa.

Doble panel (Subplots): Se recomienda pintar **ambos gráficos de forma paralela** usando 'fig, axes = plt.subplots(1, 2)' compartiendo el eje Y.

Ejemplo: Subplots de caja y violín coordinados

```
df = pd.read_csv('heart.csv')
fig, axes = plt.subplots(1, 2, figsize=(12, 5), sharey=True)
```

```
# 1. Diagrama de caja en subplot izquierdo (axes[0])
sns.boxplot(data=df, x='condition', y='thalach',
            palette=['#94A3B8', '#D92121'], ax=axes[0])
axes[0].set_title('Frecuencia cardíaca máxima (Caja)',
                loc='left')
```

```
axes[0].set_xticks([0, 1])
axes[0].set_xticklabels(['Sano (0)', 'Enfermo (1)'])
```


```
# 2. Diagrama de violín en subplot derecho (axes[1])
sns.violinplot(data=df, x='condition', y='thalach',
              palette=['#94A3B8', '#D92121'], ax=axes[1])
axes[1].set_title('Densidad y distribución (Violín)', loc='left')
axes[1].set_xticklabels(['Sano (0)', 'Enfermo (1)'])
```

```
sns.despine(fig=fig) # Limpieza conjunta de espinas
```


3. Gráficos de caja y violín agrupados

Impacto Cardíaco: Los pacientes con cardiopatía alcanzan frecuencias máximas sensiblemente inferiores

Resumen Estadístico: Frecuencia Cardíaca (Caja)



Perfil de Densidad y Dispersión (Violín)



¿Por qué el Boxplot sigue vigente frente al Violín?

VENTAJAS DEL BOXPLOT (CP = Caja y Patillas / Bigotes)

Sigue siendo el **estándar en producción y negocio**:

- **Simplicidad (3 números)**

Resume la distribución de forma unívoca en Q1, mediana (Q2), y Q3. Su decodificación es inmediata.

- **Robustez ante muestras reducidas** (N pequeño)

Funciona con precisión matemática incluso con 10 o 20 observaciones. El violín (KDE) necesita un volumen elevado de datos para que la curva sea fiable.

- **Capacidad de comparación** masiva

Su huella geométrica compacta y estrecha permite alinear docenas de categorías en el eje X (20-50 grupos) sin saturar ni colapsar el lienzo.

- **Detección** explícita y aislada **de outliers**

Identifica y grafica de forma individual cada observación extrema fuera de las patillas ($> 1.5 \times \text{IQR}$), facilitando auditorías de calidad y detección de anomalías.

¿Por qué el Boxplot sigue vigente frente al Violín?

RIESGOS DEL VIOLÍN (KDE) Y GUÍA DE DECISIÓN

Factores de **distorsión** y regla de **uso** en ciencia de datos:

- Efecto espejo y **sesgos de frontera**

La silueta simétrica **inventa densidad artificial en variables acotadas** (ej. no negativas, edad, o importes), extendiendo colas imposibles más allá de los límites.

- **Sobrecarga computacional** en Big Data

La estimación continua KDE requiere calcular integrales de convolución pesadas, siendo órdenes de magnitud **más lenta que los cuantiles aritméticos del boxplot**.

- Curva de alfabetización de la **audiencia**

Un directivo entiende un boxplot en segundos. El violín desorienta a **audiencias generales**, que **suelen confundir la anchura de densidad con la magnitud del dato**.

CRITERIO DE ELECCIÓN PRÁCTICA

- **ELIGE BOXPLOT:** En **informes ejecutivos, dashboards, más de 5 categorías, muestras pequeñas** ($N < 100$) o cuando la **auditoría de valores atípicos** sea prioritaria.
- **ELIGE VIOLÍN:** En **fases exploratorias y muestras masivas** ($N > 500$) **donde se sospeche bimodalidad o agrupamientos internos** que una caja ocultaría.

Índice

1. Estructura de gráficos avanzados para distribuciones
2. Histogramas y estimación de densidad KDE
3. Gráficos de caja y violín agrupados
4. Mapas de calor de correlación

4. Mapas de calor de correlación

Mapeo bidimensional de matrices numéricas (Correolograma)

Coefficiente de correlación de Pearson: mide el **grado de asociación lineal** bivariada **entre variables continuas**, con valores restringidos estrictamente entre -1.0 y +1.0.

El peligro de las matrices masivas: las **tablas numéricas de correlaciones fatigan** la memoria de trabajo cognitiva de **la audiencia** de manera inmediata.

Solución con Heatmaps: **codifica la magnitud numérica** en un mapa bidimensional de **color** con la directiva '**sns.heatmap**(corr, annot=True)'.

Paleta divergente simétrica obligatoria: el **cero (ausencia de correlación)** debe ser el **color neutro (gris o blanco)**, el **azul** las **negativas** y el **rojo** las **positivas**.

Ejemplo: Heatmap de correlación bivariada

```
cols = ['age', 'trestbps', 'chol', 'thalach', 'oldpeak']  
corr_matrix = df[cols].corr(method='pearson')
```

```
fig, ax = plt.subplots(figsize=(7,5, 6,5))
```

```
# Heatmap con anotaciones de texto y mapa  
divergente simétrico
```

```
sns.heatmap(corr_matrix, annot=True, fmt='.2f',  
cmap='coolwarm', vmin=-1, vmax=1, center=0,  
square=True, linewidths=0.5, cbar_kws={'shrink': 0.86},  
ax=ax)
```

```
# Ajustar etiquetas de los ejes para evitar cortes  
ax.set_title('Matriz de correlaciones cuantitativas de  
salud', pad=18)
```

```
plt.tight_layout()
```

Matriz de Correlación Bivariada en Variables de Salud Cardíaca



Tema 2

Gráficos estadísticos avanzados

Carlos Castilla Ruiz

c.castilla@upm.es
